

# SVM

## SVM

线性可分支持向量机及优化目标

拉格朗日对偶

KKT 条件

松弛变量


核技巧

SMO

参考资料

## 线性可分支持向量机及优化目标

SVM是一个二分类模型，寻找一个超平面，最大化正负类样本到该平面的最小间隔。



样本特征记为  $\vec{x}$ ， 正类样本的标记为  $+1$ ， 负类样本的标记为  $-1$ 。

超平面

$$\vec{W} \cdot \vec{X} + \vec{b} = 0 \quad (1)$$

所以

对正类样本有

$$\vec{W} \cdot \vec{X}_+ + \vec{b} \geq 1 \quad (2)$$

对负类样本有

$$\vec{W} \cdot \vec{X}_- + \vec{b} \leq -1 \quad (3)$$

支持向量则有

$$\begin{aligned} \vec{W} \cdot \vec{X}_+ + \vec{b} &= 1 \\ \vec{W} \cdot \vec{X}_- + \vec{b} &= -1 \end{aligned} \quad (4)$$

正负边界之间的距离记为  $Width$

根据余弦定理可知

$$\begin{aligned} \frac{Width}{\|\vec{X}_+ - \vec{X}_-\|} &= \frac{\vec{W} \cdot (\vec{X}_+ - \vec{X}_-)}{\|\vec{W}\| \times \|\vec{X}_+ - \vec{X}_-\|} \\ Width &= \frac{\vec{W} \cdot (\vec{X}_+ - \vec{X}_-)}{\|\vec{W}\|} \\ Width &= \frac{(1 - b) - (-1 - b)}{\|\vec{W}\|} \\ Width &= \frac{2}{\|\vec{W}\|} \end{aligned}$$

所以优化目标为

$$\begin{aligned} &\max_{w,b} \frac{2}{\|\vec{W}\|} \\ \text{等价于} \quad &\min_{w,b} \frac{1}{2} \|\vec{W}\|^2 \\ s.t. \quad &y_i * (\vec{W} \cdot \vec{X}_i + \vec{b}) \geq 1, \forall i \in 1, 2, 3, \dots, N \end{aligned}$$


---

## 拉格朗日对偶

考虑优化如下问题

$$\begin{aligned} &\min f_0(x) \\ s.t. \quad &f_i(x) \leq 0, \forall i \in 1, 2, 3, \dots, N \end{aligned}$$


该问题可转化为

$$\begin{aligned} J(x) &= \begin{cases} f_0(x), f_i(x) \leq 0 \forall i \\ \infty, otherwise \end{cases} \\ &= f_0(x) + \sum_i I[f_i(x)] \end{aligned}$$

$$I[u] = \begin{cases} 0, & if \ u \leq 0 \\ \infty, & otherwise \end{cases}$$

对违背约束条件的情况，有正无穷的惩罚。优化该问题依旧困难，所以考虑使用  $\lambda\mu$  来处理，其中  $\lambda > 0$  表示朝着  $+\infty$  方向惩罚。（因为  $\lambda\mu \geq 0$ ）

$\lambda\mu$  是  $I[u]$  的下界，当  $\lambda \rightarrow +\infty$  时，在  $\mu \geq 0$  范围内， $\lambda\mu \rightarrow +\infty$ 。与  $I[u]$  等价。见下图：



优化问题可以转为

$$L(x, \lambda) = f_0(x) + \sum_i^N \lambda_i f_i(x). \quad \forall i \in 1, 2, 3 \dots N, \lambda \geq 0 \quad (5)$$

这就是拉格朗日乘子法。

因为  $\lambda\mu$  是  $I[u]$  的下界，且  $\lambda \rightarrow +\infty$  时， $\lambda\mu \rightarrow +\infty$  即  $\lambda\mu = I[u]$

所以  $\max_{\lambda} L(x, \lambda) = J(x)$ 。

我们的目标是  $\min_x J(x)$ ，所以问题可转化为  $\min_x \max_{\lambda} L(x, \lambda)$

设  $\max_{\lambda} \min_x L(x, \lambda)$ ，且  $g(\lambda) = \min_x L(x, \lambda)$

$$\max_{\lambda} \min_x L(x, \lambda) = \max_{\lambda} g(\lambda)$$

$L(x, \lambda)$  是关于  $\lambda$  的仿射函数，又因为  $\lambda \geq 0$ ，所以  $g(\lambda)$  是凹的，所以  $\max_{\lambda} g(\lambda)$  是一个凸优化问题。

下面说明  $\max_{\lambda} \min_x L(x, \lambda)$  与  $\min_x \max_{\lambda} L(x, \lambda)$  之间的关系，以及  $g(\lambda)$  是对偶问题。

$$L(x, \lambda) \leq J(x) \quad \forall \lambda \geq 0$$

$$\Rightarrow \min_x L(x, \lambda) = g(\lambda) \leq \min_x J(x) = p^*$$

$$\Rightarrow d^* = \max_{\lambda} g(\lambda) \leq p^*$$

$p^*$  为原问题的最优解。

$d^*$ 为 $\max_{\lambda} g(\lambda)$ 的最优解。

因为 $\lambda \rightarrow +\infty$ 时,  $\lambda\mu \rightarrow +\infty$ , 所以 $\max_{\lambda} g(\lambda) \rightarrow J(x)$

又因为 $\max_{\lambda} L(x, \lambda) = J(x)$

所以

$$\max_{\lambda} \min_x L(x, \lambda) \leq \min_x \max_{\lambda} L(x, \lambda) \quad \lambda \geq 0 \quad (6)$$


---

## KKT 条件

考虑如下问题

最优化

$$\begin{aligned} & f_0(x) \\ s.t. \quad & f_i(x) \leq 0 \quad \forall i \in 1, 2, \dots, N \\ s.t. \quad & h_j(x) = 0 \quad \forall j \in 1, 2, \dots, M \end{aligned}$$

该问题的KKT条件是:

- |                                                                                                  |             |
|--------------------------------------------------------------------------------------------------|-------------|
| 1. $0 \in \partial f_0(x) + \sum_i^N \lambda_i \partial f_i(x) + \sum_j^M \mu_j \partial h_j(x)$ | 驻 点         |
| 2. $\lambda_i f_i(x) = 0 \quad \forall i \in 1, 2, \dots, N$                                     | 互 补 松 弛 条 件 |
| 3. $f_i(x) \leq 0, h_j(x) = 0 \quad \forall i \in 1, 2, \dots, N, \forall j \in 1, 2, \dots, M$  | 原 始 可 行 域   |
| 4. $\lambda_i \geq 0 \quad \forall i \in 1, 2, \dots, N$                                         | 对 偶 可 行 域   |

4是优化必须满足的条件, 后面再详细说明。

KKT是最优解 $x^*$ 的充要条件的证明, 主要证明条件1, 2.

先证明必要性:

假设 $x^*, \lambda^*, \mu^*$ 是原始问题和对偶问题在可行域的最优解, 记对偶问题为 $g(\lambda, \mu)$ 。

$$g(\lambda, \mu) = \min_x L(x, \lambda^*, \mu^*) \quad (1)$$

$$= \min_x f_0(x) + \sum_j^N \mu_j^* h_j(x) + \sum_i^M \lambda_i^* f_i(x) \quad (2)$$

$$\leq f_0(x^*) + \sum_j^N \mu_j^* h_j(x^*) + \sum_i^M \lambda_i^* f_i(x^*) \quad (3)$$

$$\leq f_0(x^*) \quad (4)$$

(2)-(3)取等号的条件是 $\lambda_i^* f_i(x^*) = 0$  所以满足KKT条件2

(3)-(4)成立的原因是 $\lambda_i \geq 0 \quad \forall i \in 1, 2, \dots, N$

因为是最优解, 所以在 $x^*$ 处, 一定有导数为0, 所以KKT条件1成立。

条件3是原始问题约束，成立。

条件4成立。

再证明充分性：

如果  $x^*, \lambda^*, \mu^*$  满足KKT条件，记对偶问题为  $g(\lambda, \mu)$ 。

$$g = g(\mu^*, \lambda^*) \quad (1)$$

$$= \min_x f_0(x) + \sum_j^N \mu_j h_j(x) + \sum_i^M \lambda_i f_i(x) \quad (2)$$

$$= f_0(x^*) + \sum_j^N \mu_j h_j(x^*) + \sum_i^M \lambda_i f_i(x^*) \quad (3)$$

$$= f_0(x^*) \quad (4)$$

(1),(2)根据定义获得。

(2)->(3)是因为KKT条件1，所以在  $x^*$  处取得极值。

(3)->(4)是因为KKT条件2。

综上所以，KKT条件是目标函数在约束条件下取得极值的充分必要条件。

下面说明为什么KKT乘子  $\lambda_i \geq 0 \quad \forall i \in 1, 2, \dots, N$

当取得极值时， $\nabla f_0(x) + \sum_j^N \mu_j \nabla h_j(x) + \sum_i^M \lambda_i \nabla f_i(x) = 0$

目标函数得梯度方向指向优化的方向，约束条件的梯度指向约束的方向。

假如  $\nabla f_0(x)$  与  $\nabla f_i(x), \nabla h_j(x)$  同向，那么  $x$  还可以沿着梯度的方向移动很小的一部分，并且既能够满足在可行域内，又能够朝着最优化的方向优化目标函数，所以此时的  $x$  并不是最优解。

所以只有在  $\nabla f_0(x)$  与  $\nabla f_i(x), \nabla h_j(x)$  异向时，才达到最优解，此时KKT乘子  $\mu_j \geq 0 \quad \forall j \in 1, 2, \dots, N$

## 松弛变量

对于一些有噪点的数据，使用硬间隔不可分，或者分隔效果不好（正负类间隔不大，而最好的情况是间隔最大化）。此时引入松弛变量  $0 \leq \xi \leq 1$ ，并修改约束条件为  $y * (\vec{W} \cdot \vec{X} + \vec{b}) \geq 1 - \xi$

优化目标调整为

$$\begin{aligned}
& \min_w \frac{1}{2} \|w\|^2 - C \sum_i^n \xi_i \\
s.t. \quad & y_i * (\vec{W} \cdot \vec{X}_i + \vec{b}) \geq 1 - \xi_i \quad \forall i \in 1, 2, \dots, N \\
& 0 \leq \xi_i \leq 1
\end{aligned}$$

其中  $C > 0$ , 是超参数, 作为惩罚因子,  $C$  越大, 对于错误分类的惩罚越大。

通过拉格朗日乘子法, 可得

$$L(w, b, \alpha, \mu, \xi) = \frac{1}{2} \|w\|^2 + C \sum_i^n \xi_i - \sum_i^n \alpha_i [y_i * (w \cdot x + \vec{b}) - 1 + \xi_i] - \sum_i^n \mu_i \xi_i \quad (7)$$

由

$$\frac{\partial L}{\partial \xi_i} = 0, \frac{\partial L}{\partial w} = 0, \frac{\partial L}{\partial b} = 0, \frac{\partial L}{\partial \alpha_i} = 0, \frac{\partial L}{\partial \mu_i} = 0$$

可得

$$C - \alpha_i - \mu_i = 0, \quad (8)$$

又因为  $\alpha_i \geq 0, \mu_i \geq 0$ ,

所以  $0 \leq \alpha_i \leq C$

$$w = \sum_i^n \alpha_i y_i x_i \quad (9)$$

$$\sum_i^n \alpha_i y_i = 0 \quad (10)$$

$1 - \xi_i - y_i * (\vec{W} \cdot \vec{X}_i + \vec{b}) = 0$  (KKT约束条件1满足该条件) 此时该样本在间隔边界上

$\xi_i = 0$  (KKT约束条件2满足该条件) 此时该样本在间隔边界上

目标是

$$\max_{\alpha} \min_{w, b, \xi} L(w, b, \alpha, \mu, \xi) = \frac{1}{2} \|w\|^2 + C \sum_i^n \xi_i - \sum_i^n \alpha_i [y_i * (\vec{W} \cdot \vec{X}_i + \vec{b}) - 1 + \xi_i] - \sum_i^n \mu_i \xi_i \quad (11)$$

先求对  $w, b, \xi$  的极小, 再求对  $\alpha$  的极大, 将(8),(9),(10)带入(7)即得到对偶问题

$$\begin{aligned}
& \frac{1}{2} \|w\|^2 + \sum_i^n \alpha_i - \sum_i^n \alpha_i y_i x_i w - \sum_i^n \alpha_i y_i b \\
= & \frac{1}{2} \sum_i^n \alpha_i y_i x_i \sum_j^n \alpha_j y_j x_j + \sum_i^n \alpha_i - \sum_i^n \alpha_i y_i x_i \sum_j^n \alpha_j y_j x_j \\
= & \sum_i^n \alpha_i - \frac{1}{2} \sum_i^n \sum_j^n \alpha_i y_i x_i \alpha_j y_j x_j \\
s.t. \quad & \sum_i^n \alpha_i y_i = 0 \\
s.t. \quad & 0 \leq \alpha_i \leq C \quad \forall i \in 1, 2, \dots, N
\end{aligned}$$

线性不可分时，使用线性支持向量机无法分离数据。此时寻找映射函数将数据进行转换或者升到高维空间，又变成线性可分数据。

前面的小节得到  $w = \sum_i^n \alpha_i y_i x_i$

所以对样本的预测可写为

$$y = \sum_i^n \alpha_i y_i x_i x + \vec{b} \quad (12)$$

同时，目标优化问题是

$$\sum_i^n \alpha_i - \frac{1}{2} \sum_i^n \sum_j^n \alpha_i y_i x_i \alpha_j y_j x_j \quad (13)$$

可以看出无论是训练优化的过程还是预测过程，我们需要计算的是样本之间的向量内积。

假如将数据升维的函数为  $\phi(x)$ ，那么

(12)变为

$$y = \sum_i^n \alpha_i y_i \phi(x_i) \phi(x) + \vec{b} \quad (14)$$

(13)变为

$$\sum_i^n \alpha_i - \frac{1}{2} \sum_i^n \sum_j^n \alpha_i \alpha_j y_i y_j \phi(x_i) \phi(x_j) \quad (15)$$

此时可继续使用线性支持向量机寻找分离超平面。

但是寻找合适的转换或者升维函数不容易，寻找映射函数的目的是为了使数据线性可分，具体的计算步骤是先映射，再求内积，就得到映射后的结果。可见最终的目标是求内积，假如有一个函数可直接得到这个内积，从而跳过映射函数，问题就很好解决了，这就是核技巧的作用。核函数可用来求解目标函数/预测函数中样本的向量内积，帮助我们省略映射函数的选择。

所以

(14)变为

$$y = \sum_i^n \alpha_i y_i K(x_i, x) + \vec{b} \quad (16)$$

(15)变为

$$\sum_i^n \alpha_i - \frac{1}{2} \sum_i^n \sum_j^n \alpha_i \alpha_j y_i y_j K(x_i, x_j) \quad (17)$$

常用的核函数有三种：

1.线性核函数 Linear Kernel

$$K(\vec{x}_i, \vec{x}_j) = \vec{x}_i^T \cdot \vec{x}_j \quad (18)$$

2.多项式核函数 Polynomial Kernel

$$K(\vec{x}_i, \vec{x}_j) = (\gamma \vec{x}_i^T \cdot \vec{x}_j + r)^p \quad \gamma > 0 \quad (19)$$

3.高斯核函数 Radial Basis Function Kernel

$$K(\vec{x}_i, \vec{x}_j) = e^{-\gamma \|\vec{x}_i - \vec{x}_j\|^2} \quad \gamma > 0 \quad (20)$$

RBF中的超参数  $\gamma$  越大，则核函数结果越小，样本差异凸显小；越大，则核函数结果越大，样本差异凸显大。

---

## SMO

### 优化目标

$$\begin{aligned} & \min_{\alpha} \frac{1}{2} \sum_i^n \sum_j^n \alpha_i y_i x_i \alpha_j y_j x_j - \sum_i^n \alpha_i \\ s.t. \quad & \sum_i^n \alpha_i y_i = 0 \\ s.t. \quad & 0 \leq \alpha_i \leq C \quad \forall i \in 1, 2, \dots, N \end{aligned}$$

$x, y$ 已知， $C$ 是超参数，变量只有 $\alpha$ ，这是一个凸二次规划问题，但是变量有N个，随着样本量增加，变量个数增加，训练效率也低下。

SMO通过每次更新两个变量解决这个问题。

因为有约束条件(1)的存在，所以每次更新需要两个变量互为约束。

记每次选择的样本为  $\alpha_1, \alpha_2$

优化目标变为

$$\begin{aligned} & \min_{\alpha_1, \alpha_2} \frac{1}{2} \alpha_1^2 K_{11} + \frac{1}{2} \alpha_2^2 K_{22} + y_1 y_2 K_{12} \alpha_1 \alpha_2 - (\alpha_1 + \alpha_2) + y_1 \alpha_1 \sum_{j=3}^n \alpha_j y_j K_{1j} + y_2 \alpha_2 \sum_{j=3}^n \alpha_j y_j K_{2j} \\ s.t. \quad & \alpha_1 y_1 + \alpha_2 y_2 = - \sum_{i=3}^n y_i \alpha_i = \varsigma \\ & 0 \leq \alpha_i \leq C, i = 1, 2 \end{aligned}$$

$\alpha_1, \alpha_2$ 是线性关系，在 $[0, C]$ 之间。假设 $\alpha_2$ 取值范围的两个端点为 $L, H$

当 $y_1 = y_2$ 时

$$\begin{aligned} & \alpha_1 + \alpha_2 = \varsigma \\ & 0 \leq \alpha_2 \leq C \\ & 0 \leq \varsigma - \alpha_2 \leq C \end{aligned} \quad (21)$$

易得

$$\begin{aligned} L &= \max(0, \alpha_1 + \alpha_2 - C) \\ H &= \min(C, \alpha_1 + \alpha_2) \end{aligned} \quad (22)$$

当 $y_1 \neq y_2$ 时

$$\begin{aligned} & \alpha_1 - \alpha_2 = \varsigma \\ & 0 \leq \alpha_2 \leq C \\ & 0 \leq \varsigma + \alpha_2 \leq C \end{aligned} \quad (23)$$

易得

$$\begin{aligned} L &= \max(0, \alpha_2 - \alpha_1) \\ H &= \min(C, C + \alpha_2 - \alpha_1) \end{aligned} \quad (24)$$

用 $\alpha_2$ 表示 $\alpha_1$ ,  $\alpha_1 = (\varsigma - y_2 \alpha_2)y_1$ , 带入优化目标式子, 得到

$$W(\alpha_2) = \frac{1}{2}K_{11}(\varsigma - \alpha_2 y_2)^2 + \frac{1}{2}K_{22}\alpha_2^2 + y_2 K_{12}(\varsigma - \alpha_2 y_2)\alpha_2 - (\varsigma - \alpha_2 y_2)y_1 - \alpha_2 + v(\varsigma - \alpha_2 y_2) + y_2 v \alpha_2 \quad (25)$$

其中

$$v = \sum_{j=3}^n \alpha_j y_j K(x_i, x_j) \quad (26)$$

对 $\alpha_2$ 求导并令其为0, 再将 $\varsigma = \alpha_1^{old}y_1 + \alpha_2^{old}y_2$ 代入, 得到 $\alpha_2$ 的更新公式

$$\alpha_2^{new,unc} = \alpha_2^{old} + \frac{y_2(E_1 - E_2)}{\eta} \quad (27)$$

其中

$$\eta = K_{11} + K_{22} - 2K_{12} \quad (28)$$

下面要分两种情况讨论

1. 当 $\eta > 0$ 时, 是标准的二次优化问题, 加上约束条件可知 $\alpha_2$ 的更新可表示为

$$\begin{aligned} \alpha_2^{new} &= \begin{cases} H, & \alpha_2^{new,unc} > H \\ \alpha_2^{new,unc}, & L < \alpha_2^{new,unc} < H \\ L, & \alpha_2^{new,unc} < L \end{cases} \\ \alpha_1^{new} &= \alpha_1^{old} + y_1 y_2 (\alpha_1^{old} - \alpha_2^{new}) \end{aligned}$$

2. 当 $\eta \leq 0$ 时, 需要将 $L, H$ 分别带入(25)计算, 谁的值越小 (在一个很小的误差范围内, 1e-8), 谁就是 $\alpha_2^{new}$

前面KKT部分已经说明满足KKT条件是优化问题的充分必要条件, 所以当所有的样本都满足KKT条件时, 此时的 $\alpha$ 就是最优解。

如果满足KKT条件, 那么对每一个 $\alpha$ 都满足如下要求:

在松弛变量一节讲到 $\alpha, \mu$ 的关系

$$\begin{aligned} 0 &\leq \alpha \leq C \\ 0 &\leq \mu \leq C \\ \alpha + \mu &= C \end{aligned} \quad (29)$$

1.  $\alpha_i = 0 \leftrightarrow y_i g(x_i) \geq 1$

如果 $\alpha = 0$ , 那么样本不是支持向量, 所以 $y_i g(x_i) \geq 1$

2.  $0 < \alpha_i < C \leftrightarrow y_i g(x_i) = 1$

如果 $0 < \alpha < C$ , 那么 $\mu > 0$ , 所以 $\xi = 0$ , 所以样本在边界上, 所以 $y_i g(x_i) = 1$

3.  $\alpha_i = C \leftrightarrow y_i g(x_i) \leq 1$

如果 $\alpha = C$ , 那么 $\mu = 0$ , 所以 $\xi > 0$ , 所以样本在两个间隔边界之间,  $g(x_i) < 1$ , 所以 $y_i g(x_i) \leq 1$

寻找两个变量的过程如下：

选择训练样本分为两层循环，外层寻找 $\alpha_1$ ，内层寻找 $\alpha_2$ 。

外层循环遍历所有 $0 < \alpha < C$ 的样本点，寻找违反KKT条件的样本，计算误差范围在 $10^{-3}$ 内，如果找不到，就遍历所有样本，寻找违反KKT条件的样本，如果找不到，则不需进行迭代，优化结束。

在找到第一个样本的前提下，寻找第二个样本，称为内层循环， $\alpha_2$ 的优化依赖于 $|E_1 - E_2|$ ，为了提高优化速度，要寻找的样本必须使 $|E_1 - E_2|$ 最大，此时因为 $\alpha_1$ 已经确定，所以 $E_1$ 也确定了，那么寻找 $E_2$ 也很简单了，如果 $E_1 > 0$ ，那么就找 $E$ 最小的样本，如果 $E_1 < 0$ ，就找 $E$ 最大的样本。如果找到的样本不能使目标函数有足够的变化，就遍历所有样本，直到目标函数有足够变化，如果遍历完仍然没有找到合适的 $\alpha_2$ ，就跳过当前的 $\alpha_1$ ，重新外层循环。

$\alpha$ 的优化也是在误差范围内的

$$\begin{aligned} \text{if } \alpha^{new} \leq 10^{-8} \text{ then } \alpha^{new} = 0 \\ \text{if } \alpha^{new} \geq C - 10^{-8} \text{ then } \alpha^{new} = C \end{aligned} \quad (30)$$

每次优化了 $\alpha$ 之后，就需要更新 $b$ 和 $E$ 。

当 $0 < \alpha_1^{new} < C$ 时，由KKT约束可得

$$\sum_{i=1}^n \alpha_i y_i K_{11} + b = y_1 \quad (31)$$

$$b_1^{new} = y_1 - \sum_{i=3}^n \alpha_i K_{i1} - \alpha_1^{new} y_1 K_{11} - \alpha_2^{new} y_2 K_{21} \quad (32)$$

又因为

$$E_1 = \sum_{i=3}^n \alpha_i y_i K_{i1} + \alpha_1^{old} y_1 K_{11} + \alpha_2^{old} y_2 K_{21} + b^{old} - y_1 \quad (33)$$

所以

$$b_1^{new} = -E_1 - y_1 K_{11} (\alpha_1^{new} - \alpha_1^{old}) - y_2 K_{21} (\alpha_2^{new} - \alpha_2^{old}) + b^{old} \quad (34)$$

同理

$$b_2^{new} = -E_2 - y_1 K_{12} (\alpha_1^{new} - \alpha_1^{old}) - y_2 K_{22} (\alpha_2^{new} - \alpha_2^{old}) + b^{old} \quad (35)$$


1.如果 $\alpha_1, \alpha_2$ 都在 $(0, C)$ 之间，那么 $b^{new}$ 取 $b_1^{new}$ 或者 $b_2^{new}$ 都可以。这一种情况对 $b$ 的更新更加精确。

2.如果都等于0或者 $C$ ，那么 $b_1^{new}, b_2^{new}$ 以及之间的值都符合KKT条件， $b^{new}$ 取两者中点即可。

对于情况2，没有找到说明，我是这么理解的：

两个样本 $X_1, X_2$ ，分别对应 $\alpha_1, \alpha_2$

1. $\alpha_1 > 0, \alpha_2 > 0$



两者都不是支持向量，所以


$$y_1(g(x_1) + b_1) > 1,$$

$$y_2(g(x_2) + b_2) > 1$$

$X_1, X_2$ 样本都在边界平面远离分离超平面的那一侧

假设 $X_1$ 离分离超平面的距离大于 $X_2$ 离分离超平面的距离，那么 $b_1$ 比 $b_2$ 大，即使 $b$ 再小一点，只要不小于 $b_2$ 都不影响 $X_1, X_2$ 的分类，所以取中间的均值就可以了。

$$2.\alpha_1 > 0, \alpha_2 = C$$



两者都不是支持向量，且有

$$y_1(g(x_1) + b_1) > 1, X_1 \text{样本在边界平面远离分离超平面的一侧}$$

$$y_2(g(x_2) + b_2) < 1, X_2 \text{样本在边界平面靠近分离超平面的一侧}$$

类似的， $b$ 比 $b_1$ 小一点，不影响 $X_1$ 的分类，比 $b_2$ 大一点，不影响 $X_2$ 的分类，所以 $b_1, b_2$ 中间的值都满足条件

## 更新误差

$$E_i^{new} = \sum_S y_j \alpha_j K(x_i, x_j) + b^{new} - y_i \quad (36)$$

$S$ 为支持向量集合

因为非支持向量的 $\alpha$ 为0,对计算没有贡献, 所以只需要计算支持向量的即可, 每次迭代只有两个变量改变了, 做全量更新有多余计算, 所以只需要在上一次的基础上, 增加本次 $\alpha$ 的变化量导致的变化即可。所以又可以写作

$$E_i^{new} = E_i^{old} + y_1(\alpha_1^{new} - \alpha_1^{old})K(x_1, x_i) + y_2(\alpha_2^{new} - \alpha_2^{old})K(x_2, x_i) + (b^{new} - b^{old}) \quad (37)$$

在SMO实现的代码中, 只更新了支持向量样本的误差, 非支持向量样本的误差没有更新, 暂时没有找到解释, 就做了这种理解: 如果是非支持向量样本,  $g(x) + b \geq y$ , 误差无法确定计算, 但是支持向量样本的误差很好计算, 所以更新误差时, 只更新 $0 < \alpha < C$ 的样本的误差。无论是训练还是预测, 非支持向量的样本对计算没有贡献, 因为根据KKT条件 $\alpha = 0$ 。

---

## 参考资料

1.统计学习方法 李航

2.Sequential Minimal Optimization:A Fast Algorithm for Training Support Vector Machines John C. Platt